Homework 3 — Indicizzazione e ricerca di file .txt con Lucene

Relazione: analyzer, costruzione del dataset, tempi di indicizzazione e valutazione con metriche

STUDENTE	MATRICOLA	EMAIL	TECNOLOGIE
Alessio Pecilli	589232	ale.pecilli@stud.uniroma3.it	Java 21+ · Maven · Lucene 10.1.0

Repository: https://github.com/Alessio-Pecilli/IDD-HW3

1 Struttura del progetto

Indexer.java
Crea un `Document` per ogni file `.txt` (campi `nome`, `contenuto`, `path`) e lo aggiunge con un `IndexWriter`. Cartella dei documenti e dell'indice da riga di comando.

Searcher.java
Legge le query da console (`nome …` / `contenuto …`), le passa al `QueryParser` e stampa score, path e tempo di risposta dei primi 10 risultati.

Valutazione.java · Metriche.java
Eseguono le query giudicate su tutta la collezione e calcolano le metriche; confrontano tre analyzer per il campo `contenuto`.

Benchmark.java
Misura il tempo di indicizzazione su sottoinsiemi crescenti della collezione e il tempo medio di risposta delle query.

scripts/build_dataset.py
Scarica le voci di Wikipedia e scrive i file `.txt` e il manifest con la ground truth (§2.2).

src/test, scripts/test_*.py
52 test automatici (JUnit + unittest), descritti in §7.

```
python3 scripts/build_dataset.py --max-voci 2300   # dataset-wiki/ + eval/manifest.tsv
mvn compile exec:java -Dexec.mainClass=it.uniroma3.idd.Indexer -Dexec.args="dataset-wiki index"
mvn exec:java -Dexec.mainClass=it.uniroma3.idd.Searcher -Dexec.args="index"
mvn exec:java -Dexec.mainClass=it.uniroma3.idd.Benchmark     # -> eval/benchmark.md
mvn exec:java -Dexec.mainClass=it.uniroma3.idd.Valutazione   # -> eval/risultati.md, eval/
top10.tsv
mvn test && python3 -m unittest discover -s scripts       # test automatici
```

2 Costruzione dei dataset

Si usano due collezioni con scopi diversi: una piccola, scritta a mano, per verificare il comportamento di ogni funzionalità con risultati prevedibili, e una grande, presa da Wikipedia, per misurare i tempi e valutare l'efficacia con le metriche.

2.1 Dataset piccolo (`dataset/`, 12 file)

I 12 file sono stati scritti a mano: 2–3 frasi ciascuno (circa 190 caratteri) su argomenti diversi (Roma antica, cucina, astronomia, motori di ricerca, Lucene…). Ogni file è stato costruito per mettere alla prova un aspetto preciso:

- **nomi con separatori diversi**: `storia_di_roma` (underscore), `motori-di-ricerca` (trattino), `Ricetta Carbonara` (spazio e maiuscola), per l'analyzer del campo `nome`;

- **forme flesse** (*pianeta*/*pianeti*, *romano*/*romana*/*romane*) ed **elisioni** (*l'impero*, *dell'informazione*), per lo stemming e l'`ElisionFilter`;
- **frasi note** (*selva oscura*, *indice invertito*), per le phrase query;
- **ambiguità volute**: la carbonara contiene *pecorino romano* e il calcio contiene *Roma*, così una query su *impero romano* restituisce anche documenti non pertinenti, utili per controllare il ranking.

Con 12 documenti i risultati di ogni query si conoscono in anticipo, quindi questa collezione è usata dai test JUnit (§7). Per la stessa ragione però non basta a valutare tempi e recall.

2.2 Dataset grande (`dataset-wiki/`, 1980 voci di Wikipedia)

Per avere una collezione realistica e, allo stesso tempo, sapere quali documenti sono rilevanti per una query, il dataset è stato costruito dall'API di *it.wikipedia.org* con lo script `scripts/build_dataset.py` in tre passi:

1. **Voci tematiche.** Per 16 categorie di Wikipedia scelte su argomenti diversi tra loro (tabella sotto) si scaricano tutte le voci che appartengono *direttamente* alla categoria (`list=categorymembers`, namespace 0, senza sottocategorie). L'appartenenza alla categoria è decisa dagli autori di Wikipedia, non da me: è quindi una **ground truth indipendente** dal sistema da valutare.
2. **Voci casuali.** Si aggiungono 3000 voci estratte a caso (`list=random`), che fanno da "rumore": allargano la collezione e contengono documenti che condividono termini con le query senza essere pertinenti (es. un calciatore di *Roma*, un film intitolato *Inferno*).
3. **Testo.** Il testo di ogni voce è scaricato come wikitext, a blocchi di 50 voci per richiesta per rispettare i limiti dell'API, e convertito in testo in chiaro: vengono tolti template, tabelle, note, immagini e markup, e la voce è troncata alle sezioni finali (*Note*, *Bibliografia*, *Collegamenti esterni*…), che contengono quasi solo link. Le voci con meno di 300 caratteri (abbozzi, redirect) sono scartate. Ogni voce diventa un file `<titolo>.txt`: il campo `nome` contiene quindi il titolo della voce, spesso con un disambiguatore tra parentesi, ad esempio `Io (astronomia)`.

Lo script scrive anche `eval/manifest.tsv`, che per ogni file riporta `pageid`, `revid` (la revisione esatta scaricata), lunghezza e codici delle categorie di appartenenza. Il manifest è nel repository, i 12 MB di testo no (`.gitignore`): si rigenerano con lo script.

Dimensione finale. Le liste delle categorie e delle voci casuali contengono 4229 voci. Per limitare il numero di richieste all'API (che rispondeva spesso *HTTP 429 Too Many Requests*) sono state scaricate le prime 2300 in ordine di `pageid`. Tolte quelle sotto i 300 caratteri restano **1980 documenti**: 923 tematici e 1057 casuali, per 12,1 milioni di caratteri di testo (12,2 MB in UTF-8). Lunghezza: minimo 300, mediana 2429, media 6126, massimo 160 481 caratteri. Per questo di alcune categorie è presente solo una parte delle voci (colonna "Nel dataset"). La ground truth è calcolata solo sui documenti presenti, quindi resta coerente.

Codice	Categoria Wikipedia	Voci nella categoria	Nel dataset
`IMP`	Imperatori romani	103	102
`GIO`	Satelliti di Giove	92	72
`SAT`	Satelliti di Saturno	77	61
`INF`	Canti dell'Inferno	34	34
`PUR`	Canti del Purgatorio	33	33
`PAR`	Canti del Paradiso	33	33
`MOT`	Motori di ricerca	111	73
`LIN`	Linguaggi di programmazione	144	105
`ALG`	Algoritmi di ordinamento	30	27
`DB`	Basi di dati	59	28
`DOG`	Dogi della Repubblica di Venezia	129	127
`PIT`	Pittori italiani del Rinascimento	239	133
`PUN`	Battaglie della seconda guerra punica	55	27
`ELE`	Elementi chimici	57	53
`FOR`	Formaggi italiani	22	6
`PAS`	Tipi di pasta	16	9
	Totale tematiche + 1057 casuali	**1234**	**923 + 1057 = 1980**

La colonna "Voci nella categoria" somma 1234 perché due voci appartengono a due categorie (CiteSeer: DB e MOT; XBase: DB e LIN), quindi le voci tematiche distinte sono 1232. Il manifest ammette più codici per documento, ma nessuna delle due è tra le voci scaricate.

3 Analyzer

Gli analyzer sono definiti per campo con un `PerFieldAnalyzerWrapper`, restituito da `Indexer.analyzer()` e usato sia in indicizzazione sia dal `QueryParser`. In questo modo query e documenti producono termini compatibili.

Campo nome — `CustomAnalyzer`
`WhitespaceTokenizer` → `LowerCaseFilter` → `WordDelimiterGraphFilter`

- `storia_di_roma` → *storia, di, roma*; `Io (astronomia)` → *io, astronomia*: il filtro spezza su `_ - . ( )` (i cambi maiuscolo/minuscolo non contano, perché il testo è già in minuscolo);
- niente stopword né stemming: il nome è breve, ogni parola conta e deve funzionare la frase `"motori di ricerca"`;
- l'estensione `.txt` finale viene tolta prima dell'indicizzazione.

Campo contenuto — `ItalianAnalyzer`
`StandardTokenizer` → elisione → minuscolo → stopword → stemming leggero

- *L'Impero Romano* → *imper, roman*; *il pianeta e i pianeti* → *pianet, pianet*;
- la scelta è verificata sperimentalmente in §6.3, confrontandola con `StandardAnalyzer` e con lo stesso analyzer italiano senza stemming.

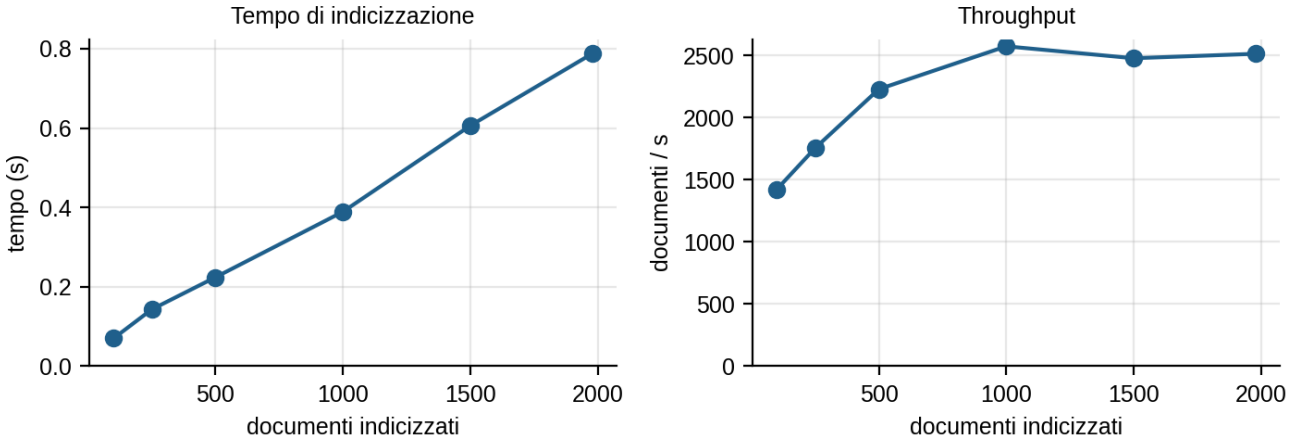
4 Indicizzazione e tempi

Il tempo è misurato da `Benchmark.java` su sottoinsiemi casuali (seed fisso) della collezione Wikipedia. Comprende apertura della `Directory`, creazione dell'`IndexWriter`, lettura dei file, analisi, `addDocument` e `commit()`. Prima delle misure si fa un'esecuzione di riscaldamento della JVM su 500 documenti, che viene

scartata; per ogni dimensione si riporta poi la mediana di 5 esecuzioni (codice compilato per Java 21, eseguito su Java 25, 8 core).

Documenti	Testo (MB)	Tempo (ms)	Documenti/s	MB/s	Indice su disco (MB)
12 (dataset piccolo)	0,002	~450*	–	–	< 0,01
100	0,5	70	1423	7,6	0,2
250	1,3	143	1754	9,2	0,5
500	2,9	224	2228	12,9	1,1
1000	5,9	389	2573	15,2	2,0
1500	9,4	606	2477	15,6	3,0
1980 (tutto)	**12,2**	**788**	**2513**	**15,5**	**3,8**

* Misura a parte, non prodotta da `Benchmark.java`: singola esecuzione di `Indexer` a JVM "fredda", dominata dall'avvio di Lucene e non dai documenti.



Tempo di indicizzazione e throughput al crescere della collezione.

- **Andamento lineare.** Da 1000 documenti in su il tempo cresce in modo proporzionale ai documenti e il throughput si stabilizza a circa 2500 documenti/s (15 MB/s di testo). Sotto i 500 documenti pesano i costi fissi (apertura dell'indice, `commit()`, creazione dei segmenti), per questo il throughput è più basso. Con i soli 12 file del dataset piccolo si misurano solo questi costi fissi.
- **Dimensione dell'indice.** L'indice occupa circa il 31% del testo (3,8 MB su 12,2 MB). Il contenuto infatti non è memorizzato (`Field.Store.NO`): l'indice contiene solo dizionario e posting list, oltre a nome e path memorizzati.
- **Tempo di risposta.** Sull'indice completo le 50 query di valutazione (primi 10 risultati, 50 ripetizioni ciascuna) richiedono in media **0,18 ms** (mediana 0,15 ms).

5 Sintassi delle query e query di test funzionali

La prima parola indica il campo (`nome` o `contenuto`), il resto è passato al `QueryParser`: termini in OR, `+termine` obbligatorio, `-termine` escluso, `AND`/`OR`/`NOT`, `"…"` per le phrase query. Il ranking è BM25 (default di Lucene). Le query seguenti, eseguite sul dataset piccolo, hanno risultati noti in anticipo e sono verificate automaticamente da `SearcherTest`:

#	Query	Query Lucene	Risultati	Cosa verifica
1	`nome roma`	`nome:roma`	storia_di_roma	split su `_`
2	`nome carbonara`	`nome:carbonara`	Ricetta Carbonara	maiuscole e spazio

3	`nome "motori di ricerca"`	`nome:"motori di ricerca"`	motori-di-ricerca	phrase query sul nome
4	`nome "ricerca motori"`	`nome:"ricerca motori"`	nessuno	nella frase l'ordine conta
5	`nome pizze`	`nome:pizze`	nessuno	sul nome niente stemming
6	`contenuto pianeti`	`contenuto:pianet`	sistema_solare	stemming (= `pianeta`)
7	`contenuto "selva oscura"`	`contenuto:"selva oscur"`	divina_commedia	phrase query
8	`contenuto +guanciale +pecorino`	`+contenuto:guancial +contenuto:pecorin`	Ricetta Carbonara	termini obbligatori
9	`contenuto romano -pecorino`	`contenuto:roman -contenuto:pecorin`	impero-romano, storia_di_roma	esclusione
10	`contenuto impero romano`	`contenuto:imper contenuto:roman`	impero-romano > storia_di_roma > Ricetta Carbonara	ranking BM25
11	`contenuto il di la`	(vuota)	nessuno	solo stopword
12	`titolo roma` · `contenuto "frase`	–	errore	campo non valido · sintassi errata

6 Valutazione dell'efficacia

6.1 Metodologia

Query e giudizi di rilevanza. In `eval/queries.tsv` ci sono 50 query, ciascuna associata a uno o più argomenti (codici della tabella §2.2). Un documento è **rilevante** per la query se nel manifest appartiene a uno di quegli argomenti. Per ogni argomento ci sono più formulazioni: parole chiave sciolte, frase esatta, termini obbligatori/esclusi e query sul campo `nome`. In questo modo si vede anche l'effetto della formulazione. Le query sono state scritte prima di guardare i risultati e non sono state modificate per migliorarli.

Esecuzione. Ogni query è eseguita sull'intera collezione e si considera *tutto* il ranking, non solo i primi 10 risultati: altrimenti la recall non si potrebbe calcolare. La rilevanza è binaria.

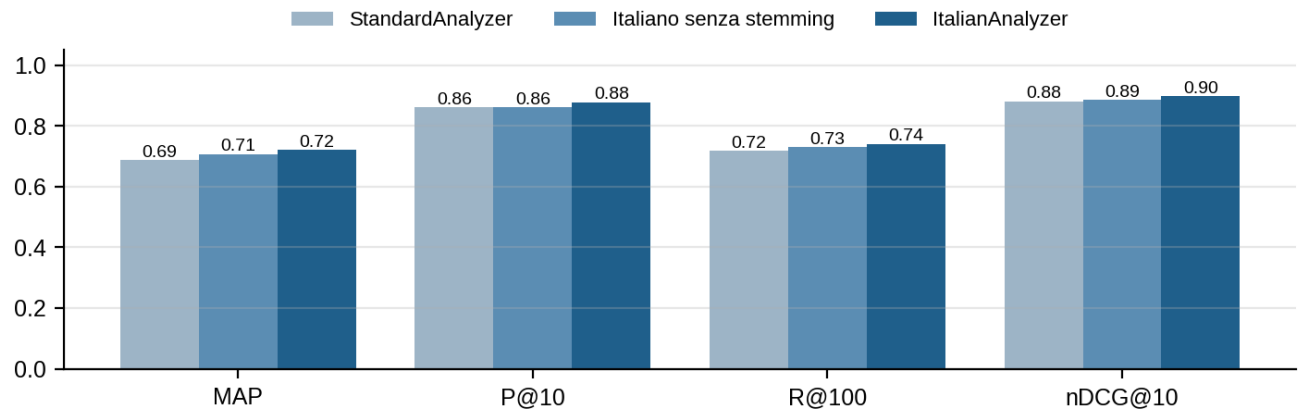
Metriche (implementate in `Metriche.java`, verificate con esempi calcolati a mano in `MetricheTest`). R è l'insieme dei rilevanti, *rel(i)* vale 1 se il documento in posizione i è rilevante:

Metrica	Definizione	Cosa misura
P@10	$\lvert rilevanti\ tra\ i\ primi\ 10 \rvert\ /\ 10$	qualità della prima pagina, quella che l'utente guarda
R@100	$\lvert rilevanti\ tra\ i\ primi\ 100 \rvert\ /\ \lvert R \rvert$	quanti rilevanti si trovano scorrendo 100 risultati
Recall	$\lvert rilevanti\ restituiti \rvert\ /\ \lvert R \rvert$	copertura dell'intero insieme restituito (tutti i documenti con almeno un termine)
R-Precision	$P@\lvert R \rvert$	precision nel punto in cui precision = recall
AP / MAP	$(1/\lvert R \rvert)\ \Sigma_{i:\ rel(i)=1}\ P@i$	qualità di tutto il ranking; i rilevanti non trovati contano 0. MAP = media su tutte le query
RR / MRR	$1\ /\ posizione\ del\ primo\ rilevante$	quanto presto compare il primo risultato utile
nDCG@10	$\Sigma_{i \le 10}\ rel(i)/log_2(i+1)\ /\ IDCG@10$	come P@10, ma pesa di più le prime posizioni

6.2 Risultati

Medie sulle 50 query (dettaglio completo per query in `eval/risultati.md`). La riga evidenziata è la configurazione scelta. Le query sul campo `nome` sono identiche nelle tre configurazioni, perché cambia solo l'analyzer del contenuto.

Analyzer contenuto	MAP	P@10	R@100	Recall	R-Prec	MRR	nDCG@10
StandardAnalyzer	0,687	0,862	0,717	0,762	0,667	0,940	0,881
Italiano senza stemming	0,707	0,862	0,729	0,780	0,689	0,953	0,886
ItalianAnalyzer (scelto)	**0,720**	**0,878**	**0,741**	**0,792**	**0,699**	**0,943**	**0,897**



Confronto delle tre configurazioni per il campo contenuto.

Una selezione di query (`ItalianAnalyzer`) mostra come la formulazione cambia il rapporto tra precision e recall:

Id	Query	|R|	Restituiti	P@10	Recall	AP	nDCG@10
q01	`contenuto imperatore romano`	102	390	1,000	0,990	0,923	1,000
q18	`contenuto "imperatore romano"`	102	37	0,800	0,324	0,276	0,842
q22	`contenuto +imperatore +impero +augusto`	102	71	1,000	0,627	0,621	1,000
q12	`contenuto doge Venezia`	127	235	1,000	0,976	0,960	1,000
q41	`contenuto "doge di Venezia"`	127	8	0,700	0,055	0,055	0,801
q21	`nome doge`	127	11	0,900	0,079	0,078	0,936
q19	`nome inferno`	34	34	1,000	1,000	1,000	1,000
q05	`contenuto canto Inferno Dante`	34	178	0,600	1,000	0,647	0,691
q11	`contenuto database`	28	62	0,700	0,750	0,395	0,556
q17	`contenuto pasta`	9	15	0,600	0,889	0,811	0,777
q48	`contenuto "formaggio a pasta"`	6	0	0,000	0,000	0,000	0,000

6.3 Discussione

- **Effetto dello stemming.** L'`ItalianAnalyzer` migliora tutte le metriche medie rispetto a `StandardAnalyzer` (MAP +0,033, Recall +0,030). Il guadagno è grande sulle query restrittive, dove una forma flessa diversa basta a escludere un documento: `+imperatore +impero +augusto` passa da AP 0,235 a 0,621 (*imperatore*/*imperatori* → *imperator*), `canto Inferno Dante` da 0,400 a 0,647 (*canto*/*canti*), la frase `"imperatore romano"` da 0,134 a 0,276. Sulle query OR molto ampie (`indice ricerca informazioni documenti`) lo stemming restituisce più documenti e perde invece qualche centesimo di AP. Le stopword e l'elisione da sole (riga intermedia) danno già circa il 60% del miglioramento della MAP.

- **Precision contro recall.** Le query OR di 2–4 parole hanno recall vicina a 1 e P@10 alta grazie al ranking BM25. Le phrase query hanno precision alta ma recall molto bassa: `"doge di Venezia"` restituisce 8 voci, di cui solo 7 dogi su 127, perché quasi tutte le voci scrivono *doge della Repubblica di Venezia*. Il campo `nome` funziona bene solo quando il titolo segue una convenzione: con `nome inferno` (titoli *Inferno - Canto …*) tutte le metriche valgono 1, mentre `nome doge` trova solo gli 11 titoli con il disambiguatore *(doge)*, di cui 10 dogi veneziani e uno genovese.
- **Errori tipici.** Per `canto Inferno Dante` i falsi positivi sono canti del Purgatorio e del Paradiso, che citano Dante e l'Inferno: sono vicini al tema ma non rispondono al bisogno informativo. `pasta` restituisce formaggi (*a pasta semicotta*, *pasta filata*): l'ambiguità è nella lingua, non nell'analyzer. `"formaggio a pasta"` non trova nulla perché i 6 formaggi presenti non contengono quella frase.

6.4 Il problema della recall: giudizi incompleti

Per calcolare la recall bisogna conoscere *tutti* i documenti rilevanti. Con 1980 documenti e 50 query ci sarebbero 99 000 coppie da giudicare a mano, cosa impraticabile. Per questo si è usata l'appartenenza alle categorie di Wikipedia, che però è una ground truth **incompleta**: un documento pertinente che non sta nella categoria conta come errore. Per stimare l'effetto si è usata l'idea del *pooling* delle campagne TREC: si sono giudicati a mano i documenti tra i primi 10 di ogni query che il manifest considera non rilevanti (`eval/giudizi_manuali.tsv`).

- Sono **44** documenti in tutto. **6** sono in realtà pertinenti e si concentrano sulle query sui database: *Data Language One*, *Clipper*, *MUMPS*, *PL/SQL*, *PowerBuilder*, *ISI Web of Knowledge*. Wikipedia li classifica in *Linguaggi di programmazione* e non in *Basi di dati*. Con questi giudizi la P@10 di q11 passa da 0,7 a 1,0, q39 da 0,8 a 0,9, q40 da 0,6 a 0,8, e la **P@10 media da 0,878 a 0,890**.
- Gli altri 38 sono errori veri del sistema (canti di un'altra cantica, il doge *di Genova* Antoniotto Adorno per `nome doge`, formaggi per `pasta`…).
- Esistono anche rilevanti non giudicati *fuori* dai primi 10. Per esempio *Temi (astronomia)*, un satellite di Saturno (poi rivelatosi inesistente), sta in un'altra categoria. Per questo la recall misurata è una **stima**: corretta come confronto tra configurazioni, perché tutte sono giudicate con la stessa ground truth, ma non in valore assoluto. Anche la P@10 va letta come limite inferiore.

7 Test automatici

I test automatici sono **52**, tutti superati (`mvn test`: 40 · `python3 -m unittest discover -s scripts`: 12).

Classe	Test	Cosa verifica
`SearcherTest`	20	Le query di §5 sul dataset piccolo: termine singolo, OR, phrase, ordine della frase, maiuscole, assenza di stemming sul nome, stemming ed elisione sul contenuto, `+` / `-` / `AND`, ordinamento BM25, stopword, termine assente, campo non valido, termini mancanti, sintassi errata, spazi multipli.
`IndexerTest`	7	Token prodotti dai due analyzer (separatori, parentesi dei titoli Wikipedia, stopword, elisione, stemming); file non `.txt` e cartelle ignorati; reindicizzare non duplica i documenti; rimozione solo del `.txt` finale.
`MetricheTest`	9	Ogni metrica su un ranking di esempio con valori calcolati a mano; ranking perfetto (tutte = 1); casi limite (ranking vuoto, nessun rilevante: niente divisioni per zero).
`ValutazioneTest`	4	Lettura di manifest e query; ground truth come unione di più argomenti; valutazione end-to-end sul dataset piccolo con giudizi scritti a mano (es. `contenuto ricerca`: precision 1 ma recall 1/5); calcolo della MAP.
`test_build_dataset.py`	12	Conversione wikitext → testo: link, grassetto, template annidati, note, tabelle, immagini e categorie, titoli ed elenchi, sezioni finali, link esterni, redirect, commenti; nomi di file validi.

8 Conclusioni e limiti

- Su 1980 documenti reali l'indicizzazione scala linearmente (circa 2500 documenti/s) e le query rispondono in meno di un millisecondo.
- Le metriche confermano la scelta dell'`ItalianAnalyzer` per il contenuto (MAP 0,720 contro 0,687) e mostrano il compromesso tra query OR (alta recall) e phrase query o query sul nome (alta precision, bassa recall).
- **Limiti.** La ground truth deriva dalle categorie ed è incompleta (§6.4). Le query le ho scritte io, conoscendo gli argomenti, quindi possono essere più "facili" di quelle di un utente reale. Il convertitore wikitext è semplificato: alcuni template che producono testo vengono eliminati: in qualche voce restano parole attaccate (*dellInstitute*) o frasi incomplete. Infine la collezione è limitata a 1980 voci per i limiti di richieste dell'API; lo script può scaricarne di più (`--max-voci`).